

PROVA 01 - PPGOLD - Data Science 1

Eduardo Pécora

2025-05-01

NOME e email UFPR:

Questão 1 - Pseudo-Código e Lógica de programação

Instruções:

- O pseudo-código não precisa ser escrito em uma linguagem específica de programação, pode ser escrito em português.
- O importante é a sequência de passos lógicos, como mostrado no exemplo, para resolver o problema.

Antes de resolver a questão 4, segue um exemplo de pseudocódigo que lê dois números e exibe a soma.

Exemplo:

```
Início
  Ler número1
  Ler número2
  soma = número1 + número2
  Exibir soma
Fim
```

- A) Escreva um pseudo-código que receba três números e determine qual é o maior entre eles, vocês não poderão usar uma função pronta, tipo `max()`.
- B) Crie um novo Jupyter e programe a sua função, teste-a com várias combinações de números, incluindo negativos, positivos, etc. Também se colocarmos um texto no lugar do número a função tem que voltar uma mensagem e erro.

Questão 2 - Pandas

Considerando o código abaixo, explique linha-linha o que ele executa, identifique as duas variáveis utilizadas e os seus tipos.

```
import pandas as pd


data = {1: ("João", 40, "Diretor"),
        2: ("Maria", 38, "Coordenadora"),
        3: ("Ricardo", 18, "Estagiário"),
        4: ("Francisco", 45, "Presidente")}
```

```
df = pd.DataFrame.from_dict(data, orient='index',
                             columns=['Nome', 'Idade', 'Cargo'])

print(df.head())
```

Questão 3 - Metodologia da Data Science

Explique cada passo do diagrama da metodologia da DataScience, completando os passos em branco.



<https://www.ibm.com/downloads/cas/B1WQ0GM2>

Questão 4 - Python e Metodologia

Para cada um dos blocos de código abaixo:

- Descreva o que ele faz.
- Encaixe-o na metodologia do Data Science.
- Defina a ordem em que devem ser executados.

BLOCO VERMELHO

```
from sklearn.model_selection import train_test_split

X = df[['variavel1', 'variavel2']]
y = df['target']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
```

BLOCO AZUL

```
import pandas as pd
df = pd.read_csv('dados.csv')
df.head()
```

BLOCO VERDE

```
print(df.describe())
print(df.isnull().sum())
```

BLOCO ROSA

```
from sklearn.metrics import mean_squared_error

y_pred = model.predict(X_test)
mse = mean_squared_error(y_test, y_pred)
print(f'MSE: {mse}')
```

BLOCO LARANJA

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)
```

Questão 5 - Interpretação de Modelo

Um modelo de regressão linear foi ajustado para prever o preço de um imóvel (Preço), com base nas seguintes variáveis independentes: Área (m²), Número de Quartos, e Idade do Imóvel (anos). Abaixo está a saída do modelo de regressão linear:

Coefficientes:

- Intercepto: 50000
 - Área (m²): 2000
 - Número de Quartos: 30000
 - Idade do Imóvel (anos): -1000
 - R^2 : 0.85
1. Escreva a equação do modelo de regressão linear com base nos coeficientes fornecidos.
 2. Explique o que significa o coeficiente da variável Área (m²) no contexto do modelo.
 3. O que significa o sinal negativo no coeficiente da variável Idade do Imóvel (anos)?
 4. Como você interpreta o valor do R^2 neste modelo?
 5. Suponha que você tenha um imóvel com 100 m² de área, 3 quartos, e 10 anos de idade. Use a equação do modelo para prever o preço desse imóvel.

Questão 6 – Programação

Com os dados abaixo faça um Código que aplique uma regressão linear, interprete os resultados com os gráficos mostrados em aula e preveja o preço de um imóvel com os dados do new_data

```
# Dataset com 20 registros
data = {
    'Área (m²)': [
        50, 60, 70, 80, 90, 100, 116, 120, 130, 140,
        55, 65, 75, 85, 95, 105, 115, 125, 135, 145,
        60, 70, 80, 90, 103, 110, 120, 130, 140, 150,
        65, 75, 85, 95, 105, 115, 125, 135, 145, 155,
        68, 78, 88, 98, 108, 118, 128, 138, 148, 158
    ],
    'Número de Quartos': [
        2, 2, 2, 3, 3, 3, 3, 4, 4, 5,
        2, 2, 2, 3, 3, 3, 4, 4, 5, 5,
        1, 2, 3, 3, 3, 4, 4, 5, 5, 5,
        2, 2, 3, 3, 3, 4, 4, 5, 5, 5,
        1, 2, 2, 3, 3, 4, 4, 5, 5, 5
    ],
    'Idade do Imóvel (anos)': [
        25, 20, 18, 15, 12, 10, 8, 6, 4, 2,
        27, 23, 19, 16, 13, 9, 7, 5, 3, 1,
        30, 28, 25, 22, 19, 15, 10, 7, 3, 1,
        29, 24, 20, 16, 11, 8, 6, 4, 2, 0,
        26, 22, 17, 13, 9, 6, 3, 2, 1, 0
    ],
    'Preço (R$)': [
        220000, 253405, 270000, 310000, 340101, 370000, 410000, 450000,
        490000, 550000,
        240000, 260000, 290000, 330000, 369821, 400011, 448900, 480000,
        530000, 580000,
        200000, 230000, 286272, 320782, 360670, 408710, 440000, 490000,
        530000, 588910,
        210022, 240000, 290000, 330000, 370000, 429260, 468980, 500000,
        550000, 601862,
        190000, 220000, 250000, 300800, 350000, 390462, 430000, 480000,
        537868, 591189
    ]
}
```

```
new_data = pd.DataFrame({
    'Área (m²)': [90],
    'Número de Quartos': [3],
    'Idade do Imóvel (anos)': [7]
})
```